

# 概率论与数理统计

眠云跂石整理

## 第 1 章 事件的概率

组合公式

事件的运算

## 第 2 章 随机变量及概率分布

### 2.1 一维随机变量

#### 2.1.1 离散型随机变量

1 二项分布

2 泊松分布

3 超几何分布

4 负二项分布

5 几何分布

5' 几何分布

#### 2.1.2 连续型随机变量

1 正态分布

2 指数分布

3 威布尔分布

4 均匀分布

5 对数正态分布

6 柯西分布

7 拉普拉斯分布

### 2.2 多维随机变量

#### 2.2.1 离散性随机向量

1 多项分布

#### 2.2.2 连续型随机向量

1 矩形均匀分布

2 二维正态分布

3 多元正态分布

#### 2.2.3 边缘分布

1 概念解释

2 多项分布

3 二维正态分布

### 2.3 条件概率分布与随机变量的独立性

#### 2.3.1 条件概率分布的概念

#### 2.3.2 离散性随机变量的条件概率分布

#### 2.3.3 连续性随机变量的条件概率分布

#### 2.3.4 随机变量的独立性

### 2.4 随机变量的函数的概率分布

#### 2.4.1 离散性分布

#### 2.4.2 连续型分布

##### 1 单变量函数

1.1 严格单调

1.2 幂函数

##### 2 多变量函数

#### 2.4.3 随机变量和的密度函数

#### 2.4.4 随机变量商的密度函数

注意事项

## 第 3 章 随机变量的数字特征

### 3.1 数学期望与中位数

#### 3.1.1 数学期望的定义

#### 3.1.2 数学期望的性质

#### 3.1.3 条件数学期望 (条件均值)

#### 3.1.4 中位数

### 3.2 方差与矩

#### 3.2.1 方差和标准差

#### 3.2.2 矩

### 3.3 协方差与相关系数

#### 3.3.1 协方差

#### 3.3.2 相关系数

### 3.4 大数定理和中心极限定理

3.4.1	大数定理
3.4.2	中心极限定理
3.5	母函数
3.5.1	母函数的定义
3.5.2	常见分布的母函数
3.5.2	母函数的性质
3.5.3	独立和的母函数
3.6	特征函数
3.6.1	特征函数的定义
3.6.2	常见分布的特征函数
3.6.3	特征函数的性质
	例题
第 4 章	参数估计
4.1	数理统计学的基本概念
4.2	点估计
4.2.1	矩估计法
4.2.2	极大似然估计法
4.2.3	贝叶斯估计法
4.3	点估计的优良性准则
4.3.1	估计量的无偏性
4.3.2	最小方差无偏估计
1	均方误差
2	最小方差无偏估计 (MVU 估计)
3	克拉美 - 劳不等式
4.3.3	估计量的相合性与渐进正态性
1	相合性
2	渐进正态性
4.4	区间估计
4.4.1	基本概念
4.4.2	枢轴变量法
4.4.3	大样本法
4.4.4	置信界
4.4.5	贝叶斯法
第 5 章	假设检验
5.1	问题提法和基本概念
5.1.1	例子与问题提法
5.1.2	功效函数
5.1.3	两类错误, 检验的水平
5.1.4	一致最优检验

# 第 1 章 事件的概率

## 组合公式

由  $(a + b)^n = \sum_{i=0}^n \binom{n}{i} a^i b^{n-i}$  知

$$\begin{aligned}\binom{n}{0} + \binom{n}{1} + \cdots + \binom{n}{n} &= 2^n \\ \binom{n}{0} - \binom{n}{1} + \cdots + (-1)^{-1} \binom{n}{n} &= 0\end{aligned}$$

由  $(1 + x)^{m+n} = (1 + x)^m (1 + x)^n$  知

$$\binom{m+n}{k} = \sum_{i=0}^k \binom{m}{i} \binom{n}{k-i}$$

特别地, 当  $m = k = n$  时,

$$\binom{2n}{n} = \sum_{i=0}^n \binom{n}{i}^2$$

第一式还可以写作下式, 并可以从直观上理解.

$$\sum_{k_1+k_2=k} \binom{n_1}{k_1} \binom{n_2}{k_2} = \binom{n_1+n_2}{k_1+k_2}$$

此外还有下式, 也可以从直观上理解.

$$\sum_{n_1+n_2=n} \binom{n_1}{k_1} \binom{n_2}{k_2} = \binom{n_1+n_2+1}{k_1+k_2+1}$$

多项式系数:  $\frac{n!}{r_1! \cdots r_k!}$ .

利用第一式 (杨辉恒等式) 数归得第二式 (或直观理解)

$$\binom{n+m}{m} + \binom{n+m}{m+1} = \binom{n+m+1}{m+1}$$

$$\sum_{r=0}^m \binom{n-1+r}{r} = \binom{n+m}{m}$$

由负指数二项展开式  $(1-x)^{-r} = \sum_{i=0}^{\infty} \binom{-r}{i} (-x)^i = \sum_{i=0}^{\infty} \binom{i+r-1}{r-1} x^i$  知

$$\sum_{i=0}^{\infty} \binom{i+r-1}{r-1} = 0$$

$$\sum_{i=0}^{\infty} \binom{i+r-1}{r-1} (-1)^i = 2^{-r}$$

$$p^{-r} = \sum_{i=0}^{\infty} \binom{i+r-1}{r-1} p^r (1-p)^i$$

原式两边求导, 并令  $x = 1-p$ , 得

$$rp^{-r-1} = \sum_{i=0}^{\infty} i \binom{i+r-1}{r-1} (1-p)^{i-1}$$

[Stirling 数](#), [拆分数](#), [装箱问题](#), [Burnside 定理与 Polya 定理](#)

## 事件的运算

- 记号
  - $A+B \equiv A \cup B$ .
  - $AB \equiv A \cap B$ .
  - $A-B \equiv A\overline{B}$ .
- 加法
  - 交换律:  $A+B = B+A$ .
  - 结合律:  $(A+B)+C = A+(B+C)$ .  
于是可定义  $A+B+C = (A+B)+C$ .
  - 自加:  $A+A = A$ .
- 乘法
  - 交换律:  $AB = BA$ .
  - 结合律:  $(AB)C = A(BC)$ .  
于是可定义  $ABC = (AB)C$ .
  - 自乘:  $AA = A$ .
- 分配律
  - 加法与乘法:  $(A+B)C = AC+BC$ .
  - 减法与乘法:  $(A-B)C = AC-BC$ .

本质为  $ABC = (AC)(BC)$ , 这个式子在推导中是有用的.

- 减法

- $A - B = A\bar{B} \neq A + (-B)$ .
- $A \subseteq B \Leftrightarrow A - B = \emptyset$ .
- $A = B \Leftrightarrow A - B = B - A = \emptyset$ .

- 无消去律

- $A + B = A + C \nRightarrow B = C$ .
- $A - B = A - C \nRightarrow B = C$ .

- 混合运算

- $(A + B) - C \neq A + (B - C)$ . (因为减法本质上是乘法)  
因此  $A + B - C$  没有意义, 除非定义运算顺序或优先级.
- $A - (B + C) = A - B - C = (A - C) - (B - C)$ .
- $A - (B - C) = (A - B)C = AC - BC$ .

- 负号 (补集)

- $-(A + B) = (-A)(-B)$ .
- $-(A - B) = B - A = (-A)B$ .
- $-(AB) = (-A) + (-B)$ .

理论上可以这么写, 实际上用  $\bar{A}$  的符号会更方便.

- 互斥

- $A$  与  $B$  互斥  $\Leftrightarrow AB = \emptyset \Leftrightarrow P(AB) = 0$ .
- $AC = BC \Leftrightarrow A - B$  与  $B - A$  均与  $C$  互斥  $\Leftrightarrow P(\bar{A}BC) = P(\bar{A}BC) = 0$ .  
当且仅当  $C = \Omega$  时, 可由此推出  $A = B$ .
- $A$  与  $B$  互斥  $\Rightarrow AC$  与  $BC$  互斥  $\Rightarrow P(C(A + B)) = P(AC) + P(BC)$ .

- 对立

- $A$  与  $B$  对立  $\Leftrightarrow AB = \emptyset$  且  $A + B = \Omega$ .
- $\overline{A_1 A_2 \cdots A_n} = \bar{A}_1 + \bar{A}_2 + \cdots + \bar{A}_n$ .
- $\overline{A_1 + A_2 + \cdots + A_n} = \bar{A}_1 \bar{A}_2 \cdots \bar{A}_n$ .

- 条件概率

- 定义:  $P(A | B) = P(AB) / P(B)$ .
- 全概率公式: 若两两互斥的  $B_i$  之交为必然事件, 则  $P(A) = P(B_1)P(A | B_1) + P(B_2)P(A | B_2) + \cdots$ .
- 贝叶斯公式:
  - $P(B | A) = \frac{P(B)P(A | B)}{P(A)}$ .
  - $P(B_i | A) = \frac{P(AB_i)}{P(A)} = \frac{P(B_i)P(A | B_i)}{\sum P(B_j)P(A | B_j)}$ .

- 几率

- 定义:  $O(A) = \frac{P(A)}{1 - P(A)} = \frac{P(A)}{P(\bar{A})}$ .
- 贝叶斯公式:  $O(B | A) = \frac{P(B | A)}{P(\bar{B} | A)} = \frac{P(B)P(A | B)}{P(A)P(\bar{B} | A)} = \frac{P(B)P(A | B)}{P(\bar{B})P(A | \bar{B})} = O(B) \frac{P(A | B)}{P(A | \bar{B})}$ .
- 贝叶斯因子:  $BF = \frac{P(A | B)}{P(A | \bar{B})}$ , 故  $O(B | A) = BF \cdot O(B)$ .

- 促进作用的性质

- 具有对称性:  $A$  促进  $B$ , 则  $B$  促进  $A$ , 即  
 $P(A | B) > P(A) \Leftrightarrow P(B | A) > P(B)$ .
- 不具有传递性:  $B$  促进  $A$  且  $C$  促进  $B$  不能推出  $C$  促进  $A$ , 即  
 $P(A | B) > P(A), P(B | C) > P(B) \nRightarrow P(A | C) > P(A)$ .
- 若  $B$  和  $C$  都促进  $A$ , 则  $B + C$  一定促进  $A$ , 但  $BC$  和  $B - C$  不一定促进  $A$ , 即  
 $P(A | B) > P(A), P(A | C) > P(A) \Leftrightarrow P(A | B + C) > P(A)$ .
- 若  $B$  促进  $A$ , 则  $\bar{B}$  抑制  $A$ ,  $B$  抑制  $\bar{A}$ ,  $\bar{B}$  促进  $\bar{A}$ , 即

$$P(A|B) > P(A) \Leftrightarrow P(A|\bar{B}) < P(A) \Leftrightarrow P(\bar{A}|B) < P(\bar{A}) \Leftrightarrow P(\bar{A}|\bar{B}) > P(\bar{A}).$$

$$P(A|B) = P(A) \Leftrightarrow P(A|\bar{B}) = P(A) \Leftrightarrow P(\bar{A}|B) = P(\bar{A}) \Leftrightarrow P(\bar{A}|\bar{B}) = P(\bar{A}).$$

- 独立

- $A$  与  $B$  独立  $\Leftrightarrow P(AB) = P(A)P(B) \Rightarrow P(A|B) = P(A)$ .
  - 两两独立:  $\forall i, j (1 \leq i, j \leq n, i \neq j) : P(A_i A_j) = P(A_i)P(A_j)$ .
  - 相互独立:  $\forall 1 < k \leq n, 1 \leq i_1 < i_2 < \dots < i_k \leq n : P(A_{i_1} A_{i_2} \dots A_{i_k}) = P(A_{i_1})P(A_{i_2}) \dots P(A_{i_k})$ .
  - 相互独立  $\Rightarrow$  两两独立, 反之不一定成立.
  - 独立事件的任一部分也独立.
  - 若  $A_1, A_2, \dots, A_n$  独立,  $B_i = A_i$  或  $\bar{A}_i$ , 则  $B_1, B_2, \dots, B_n$  也独立.

- 独立事件的概率

- 乘法:  $P(\prod E_i) = \prod P(E_i)$ .
  - 加法:  $P(\sum E_i) = 1 - P(\prod \bar{E}_i) = 1 - \prod P(\bar{E}_i)$ .
  - 实例:

$$P(E_0 + E_1 E_2) = 1 - P(\bar{E}_0 \bar{E}_1 \bar{E}_2) = 1 - (1 - P(E_0))(1 - P(E_0 E_1))$$

$$= P(E_0) + P(E_1)P(E_2) - P(E_0)P(E_1)P(E_2).$$

- 运算定理

- 加法定理 (并集):  $P(A + B) = P(A) + P(B) \Leftrightarrow AB = \emptyset \Leftrightarrow P(AB) = 0$ .
  - 减法定理 (差集):  $P(A - B) = P(A) - P(B) \Leftrightarrow A \supseteq B \Leftrightarrow P(B - A) = 0$ .
  - 乘法定理 (交集):  $P(AB) = P(A)P(B) \Leftrightarrow A$  与  $B$  独立.
  - 加法推论 (补集):  $P(A^c) = P(\bar{A}) = 1 - P(A)$  恒成立.

- 表为互斥事件

- $\sum A_i = A_1 + \bar{A}_1 A_2 + \dots + \bar{A}_1 \bar{A}_2 \dots \bar{A}_{n-1} A_n$ .
    - $A + B = A + (B - A)$ .
    - $A + B + C = A + (B - A) + (C - B - A)$ .
  - 设  $f(m) = \sum_{k,l} \left( \prod_{i=1}^m A_{k_i} \prod_{j=1}^{n-m} \bar{A}_{l_j} \right)$ , 则  $\sum_{i=1}^n A_i = \sum_{m=1}^n f(m)$ .
    - $A + B = (B - A) + (A - B) + AB$ .
    - $$A + B + C = ABC + (BC - A) + (AC - B) + (AB - C) + (A - B - C) + (B - A - C) + (C - A - B)$$
  - 综合应用
    - $A + B = A + (B - A) = (A - B) + B = (B - A) + (A - B) + AB$ ,  
即  $A + B = A + \bar{A}B = \bar{A}B + \bar{A}\bar{B} + AB$ .
    - $P(A + B) = P(A) + P(\bar{A}B) = P(\bar{A}B) + P(\bar{A}\bar{B}) + P(AB)$ .

- 容斥原理

- $P(A + B) = P(A) + P(B) - P(AB)$ , 或  $P(AB) = P(A) + P(B) - P(A + B)$ .
  - $P(\bar{A}B) = P(\bar{A} + \bar{B})$ ,  $P(\bar{A}B) + P(\bar{A}\bar{B}) = P(\bar{A}) + P(\bar{B})$ .
  - $P(A + B + C) = P(A) + P(B) + P(C) - P(AB) - P(BC) - P(CA) + P(ABC)$ .

- 恒等式

- 化简含括号的运算
    - $(A + B) + (A - B) = A + B$ .
    - $(A + B) - (A - B) = B$ .
    - $(A - B) + (B - A) = (A + B) - AB$ .
    - $(A - B) - (B - A) = A - B$ .
  - 有用的概率恒等式
    - $A - B = A - AB$ , 或  $\bar{A}B = A\bar{A}B$ .
    - $P(A - B) = P(A) - P(AB)$ . (利用减法定理)  
 $P(AB) = P(A) - P(\bar{A}B)$ .
    - $P(\bar{A}B) = P(A) - P(AB) = P(A) - P(B) + P(\bar{A}B)$ .

- 例题

- 欧拉装错信封:  $P_n = \sum_{k=0}^n \frac{(-1)^k}{k!}$ .
- 先胜  $n$  局者为胜, 甲  $a$  胜  $b$  负, 则甲胜的概率为:  $P_n(a, b) = \sum_{i=1}^{n-b} p^{n-a-1+i} (1-p)^{n-b-i} \binom{2n-a-b-1}{n-a-1+i}$ .
- 设  $n$  个独立事件  $A_1, A_2, \dots, A_n$  的概率分别为  $p_1, p_2, \dots, p_n$ , 记  $p = p_1 + p_2 + \dots + p_n$ , 则
  - $A_1, A_2, \dots, A_n$  都不发生的概率小于  $e^{-p}$ .
  - $A_1, A_2, \dots, A_n$  中至少发生  $k$  个的概率小于  $p^k/k!$ .
- 蒲丰投针问题:  $p = \frac{2l}{\pi a}$ .

## 概率的公理化定义

1. 非负性.
2. 规范性.
3. 可列可加性.

### 定理 1 独立事件的交与并

若  $A$  和  $B$  均与  $C$  独立, 则  $AB$  与  $C$  独立  $\Leftrightarrow A + B$  与  $C$  独立.

#### 证明

- 法一

1. 必要性

$$\begin{aligned} P((A+B)C) &= P(AC + BC) \\ &= P(AC) + P(BC) - P(ABC) \\ &= P(C)(P(A) + P(B) - P(AB)) \\ &= P(C)P(A+B). \end{aligned}$$

2. 充分性

$$\begin{aligned} P(ABC) &= P((AC)(BC)) \\ &= P(AC) + P(BC) - P((A+B)C) \\ &= P(C)(P(A) + P(B) - P(A+B)) \\ &= P(C)P(AB). \end{aligned}$$

- 法二

1. 必要性

$$\begin{aligned} P((A+B)C) &= P((A-B)C) + P((B-A)C) + P(ABC) \\ &= P(AC - ABC) + P(BC - ABC) + P(ABC) \\ &= P(A)P(C) - P(AB)P(C) + P(B)P(C) - P(AB)P(C) + P(AB)P(C) \\ &= P(C)(P(A) + P(B) - P(AB)) \\ &= P(C)P(A+B). \end{aligned}$$

2. 充分性

$$\begin{aligned} P(ABC) &= P((A+B)C) - P((A-B)C) - P((B-A)C) \\ &= P(A+B)P(C) - P(AC - ABC) - P(BC - ABC) \\ &= P(A+B)P(C) - P(A)P(C) + P(ABC) - P(B)P(C) + P(ABC) \\ &= P(AC) + P(BC) - P((A+B)C) \\ &= P(C)(P(A) + P(B) - P(A+B)) \\ &= P(C)P(AB). \end{aligned}$$

### 推论 增加互斥条件的充分条件

若  $A$  和  $B$  均与  $C$  独立, 且  $A$  与  $B$  互斥, 则  $AB$  与  $A+B$  均与  $C$  独立.

### 定理 2 相互独立的充要条件

设  $0 < P(A) < 1$ , 则  $P(B|A) = P(B|\bar{A})$  是事件  $A, B$  相互独立的充要条件.

#### 证明

1. 必要性

$$\begin{aligned} P(B) &= P(AB) + P(\overline{A}B) \\ &= P(A)P(B|A) + P(\overline{A})P(B|\overline{A}) \\ &= P(B|A) = P(AB)/P(A). \end{aligned}$$

2. 充分性

$$\begin{aligned} P(B|A) &= P(AB)/P(A) = P(B) \\ &= P(AB) + P(\overline{A}B) \\ &= P(A)P(B|A) + P(\overline{A})P(B|\overline{A}) \\ &= P(B|\overline{A}). \end{aligned}$$

**推论** 相互独立的充要条件

设  $0 < P(A) < 1$ , 则  $P(A|B) = P(\overline{A}|B)$  是事件  $A, B$  相互独立的充要条件.

## 第 2 章 随机变量及概率分布

### 2.1 一维随机变量

常见分布更详细的信息请见笔记附录 ([源代码](#) 或 [PDF](#))

注意各分布的定义在不同资料上可能不同, 请注意区分.

#### 2.1.1 离散型随机变量

概率函数, 分布表,

分布函数是一个右连续的不减函数.

##### 1 二项分布

$X \sim B(n, p)$ .

理解: 事件发生的概率为  $p$ , 则重复  $n$  次试验, 事件发生的次数为  $x$ .

概率分布:  $P(X = i) = b(i; n, p) = \binom{n}{i} p^i (1-p)^{n-i}$ .

最可能数:  $x = \lfloor (n+1)p \rfloor$ .

##### 2 泊松分布

$X \sim P(\lambda)$ .

理解: 单位时间内事件平均发生  $\lambda$  次, 则某一段单位时间内发生的次数为  $x$ .

概率分布:  $P(X = i) = \lim_{n \rightarrow \infty} b(i; n, \frac{\lambda}{n}) = \frac{e^{-\lambda} \lambda^i}{i!}$ .

当二项分布满足  $n > 50, p < 0.1, np < 5$  时, 用泊松分布近似效果较好.

##### 3 超几何分布

$X \sim H(N, n, M)$ .

理解:  $N$  件产品中有  $M$  件次品, 从总体中抽  $n$  件时次品的数量  $m$ .

概率分布:  $P(X = m) = \frac{\binom{M}{m} \binom{N-M}{n-m}}{\binom{N}{n}}$ .

##### 4 负二项分布

$X \sim NB(r, p)$ .

理解: 合格率为  $p$ , 抽取到  $r$  个合格产品时, 抽到的不合格产品的个数  $x$ .

概率分布:  $P(X = i) = d(i; r, p) = \binom{i+r-1}{r-1} p^r (1-p)^i$ .

## 5 几何分布

$$X \sim GE(p).$$

理解: 合格率为  $p$ , 抽取到第一个合格产品时, 抽到的不合格产品的个数  $x$ .

$$\text{概率分布: } P(X = i) = p(1 - p)^i.$$

几何分布具有无记忆性.

## 5' 几何分布

$$X \sim G(p).$$

理解: 合格率为  $p$ , 抽取到第一个合格产品时, 抽到的总产品的个数  $x$ .

$$\text{概率分布: } P(X = i) = p(1 - p)^{i-1}.$$

几何分布具有无记忆性.

## 2.1.2 连续型随机变量

概率分布函数, 概率密度函数

注: 以下偏度系数定义为  $\beta_1 = \mu_3/\mu_2^{3/2}$ , 峰度系数定义为  $\beta_2 = \mu_4/\mu^2$ .

### 1 正态分布

$$X \sim N(\mu, \sigma^2).$$

$$\text{概率密度函数: } f(x) = (\sqrt{2\pi}\sigma)^{-1} e^{-\frac{(x-\mu)^2}{2\sigma^2}}.$$

$$\text{标准正态分布: } Y = (X - \mu)/\sigma \sim N(0, 1).$$

$3\sigma$  原则: 0.6826, 0.9544, 0.9974.

$$\text{上 } \alpha \text{ 分位数: } \Phi(z_\alpha) = 1 - \alpha.$$

### 2 指数分布

$$X \sim E(\lambda).$$

$$\text{概率密度函数: } f(x) = \begin{cases} \lambda e^{-\lambda x}, & x > 0, \\ 0, & x \leq 0. \end{cases}$$

$$\text{分布函数: } F(x) = \begin{cases} 0, & x \leq 0, \\ 1 - e^{-\lambda x}, & x > 0. \end{cases}$$

指数分布具有无记忆性, 即  $P(X > m + t \mid X > m) = P(X > t)$ .

### 3 威布尔分布

$$\text{概率密度函数: } f(x) = \begin{cases} \lambda \alpha x^{\alpha-1} e^{-\lambda x^\alpha}, & x > 0, \\ 0, & x \leq 0. \end{cases}$$

$$\text{分布函数: } F(x) = \begin{cases} 1 - e^{-\lambda x^\alpha}, & x > 0, \\ 0, & x \leq 0. \end{cases}$$

### 4 均匀分布

$$X \sim R(a, b).$$

$$\text{概率密度函数: } f(x) = \begin{cases} 1/(b-a), & a \leq x \leq b, \\ 0, & x < a \text{ 或 } x > b. \end{cases}$$

$$\text{分布函数: } F(x) = \begin{cases} 0, & x \leq a, \\ (x-a)/(b-a), & a < x < b, \\ 1, & x \geq b. \end{cases}$$



## 5 对数正态分布

$\ln X \sim N(\mu, \sigma^2)$ .

概率密度函数:  $f(x, \mu, \sigma) = \begin{cases} (x\sqrt{2\pi}\sigma) \exp\left[-\frac{(\ln x - \mu)^2}{2\sigma^2}\right], & x > 0, \\ 0, & x \leq 0. \end{cases}$

## 6 柯西分布

$X \sim C(\gamma, x_0)$ .

概率密度函数:  $f(x; x_0, \gamma) = \frac{1}{\pi} \cdot \frac{\gamma}{(x - x_0)^2 + \gamma^2} \quad (-\infty < x < +\infty)$ .

## 7 拉普拉斯分布

$X \sim \text{La}(\mu, b)$ .

概率密度函数:  $f(x) = \frac{1}{2\lambda} e^{-\frac{|x-\mu|}{\lambda}}$ .

## 2.2 多维随机变量

常见分布更详细的信息请见笔记附录 ([源代码](#) 或 [PDF](#))

### 2.2.1 离散性随机向量

#### 1 多项分布

$X = (X_1, \dots, X_n) \sim M(N; p_1, \dots, p_n)$ .

$$P(X_1 = k_1, X_2 = k_2, \dots, X_n = k_n) = \frac{N!}{k_1! k_2! \dots k_n!} p_1^{k_1} p_2^{k_2} \dots p_n^{k_n}.$$

多项分布的边缘分布是二项分布.

$(X_1, X_2, \dots, X_n) \sim M(N; p_1, p_2, \dots, p_n) \Rightarrow X_1 + X_2 \sim B(N; p_1 + p_2)$ .

### 2.2.2 连续型随机向量

#### 1 矩形均匀分布

#### 2 二维正态分布

$X = (X_1, X_2) \sim N(a, b, \sigma_1^2, \sigma_2^2, \rho)$ .

$$f(x_1, x_2) = (2\pi\sigma_1\sigma_2\sqrt{1-\rho^2})^{-1} \exp\left[-\frac{1}{2(1-\rho^2)}\left(\frac{(x_1-a)^2}{\sigma_1^2} - \frac{2\rho(x_1-a)(x_2-b)}{\sigma_1\sigma_2} + \frac{(x_2-b)^2}{\sigma_2^2}\right)\right].$$

当且仅当  $\rho = 0$  时,  $X_1$  和  $X_2$  独立.

#### 其它性质

- 二维正态分布的[边缘分布](#)是正态分布.
- 二维正态分布的[条件分布](#)是正态分布.

若  $(X, Y) \sim N(a, b, \sigma_1^2, \sigma_2^2, \rho)$ , 则给定  $X = x$  时  $Y$  的条件分布为

$$N(b + \rho\sigma_2\sigma_1^{-1}(x - a), \sigma_2^2(1 - \rho^2)).$$

- 二维正态分布的[边缘分布的和](#)仍为正态分布

若  $(X_1, X_2) \sim N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$ , 则  $Y = X_1 + X_2 \sim N(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2 + 2\rho\sigma_1\sigma_2)$ .

- [独立](#)的正态分布的[联合分布](#)是正态分布.

正态分布的联合分布不一定是二维正态分布.

- 相互独立的正态分布的和仍为正态分布

若  $X_i \sim N(\mu_i, \sigma_i^2)$ , 则  $X_1 + \dots + X_n \sim N(\mu_1 + \dots + \mu_n, \sigma_1^2 + \dots + \sigma_n^2)$ .

- 若  $Y = X_1 + X_2$  服从正态分布,  $X_1, X_2$  独立, 则  $X_1, X_2$  也是正态分布. ★

### 3 多元正态分布

设  $(X_1, X_2, \dots, X_n)$  为  $n$  元随机变量, 令

$$\mathbf{x} = \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix}, \quad \boldsymbol{\mu} = \begin{pmatrix} \mu_1 \\ \mu_2 \\ \vdots \\ \mu_n \end{pmatrix}, \quad \mathbf{C} = \begin{pmatrix} c_{11} & c_{12} & \cdots & c_{1n} \\ c_{21} & c_{22} & \cdots & c_{2n} \\ \vdots & \vdots & & \vdots \\ c_{n1} & c_{n2} & \cdots & c_{nn} \end{pmatrix},$$

其中  $\mathbf{C}$  为[协方差矩阵](#). 如果  $(X_1, X_2, \dots, X_n)$  的概率密度函数为

$$f(x_1, x_2, \dots, x_n) = \frac{e^{-\frac{1}{2}(\mathbf{x}-\boldsymbol{\mu})^T \mathbf{C}^{-1}(\mathbf{x}-\boldsymbol{\mu})}}{(2\pi)^{\frac{n}{2}} |\mathbf{C}|^{\frac{1}{2}}}$$

则称  $(X_1, X_2, \dots, X_n)$  是参数为  $\boldsymbol{\mu}, \mathbf{C}$  的  $n$  元正态变量.

#### 其它性质

- $n$  维正态分布的[边缘分布](#)是正态分布.
- $n$  维正态分布的[条件分布](#)是正态分布.
- $n$  维正态分布的[边缘分布的和](#)是正态分布.
- $n$  维随机变量  $(X_1, X_2, \dots, X_n)$  服从  $n$  维正态分布的充要条件是:

$$\forall l_i \in \mathbb{R} (i = 1, 2, \dots, n) : l_1 X_1 + l_2 X_2 + \cdots + l_n X_n \sim N(\mu, \sigma^2).$$

- 若  $Y_1, Y_2, \dots, Y_m$  都是  $n$  维正态分布分量  $X_i (i = 1, 2, \dots, n)$  的[线性函数](#), 则  $(Y_1, Y_2, \dots, Y_m)$  服从  $m$  维正态分布.
- $n$  维正态分布各分量[相互独立](#)充要条件是它们[两两不相关](#).

### 2.2.3 边缘分布

#### 1 概念解释

- 随机向量的分布可以决定其任一分量的边缘分布, 但反之不亦然.
- 随机向量也叫作其边缘分布的 **联合分布**.
- 类似的有二维的边缘分布.

#### 2 多项分布

$(X_1, \dots, X_n) \sim M(N; p_1, \dots, p_n)$  关于  $X_1$  的边缘分布为  $M(N, p_1)$ .

#### 3 二维正态分布

$(X_1, X_2) \sim N(a, b, \sigma_1^2, \sigma_2^2, \rho)$  关于  $X_1$  和  $X_2$  的边缘分布分别是  $N(a, \sigma_1^2)$  和  $N(b, \sigma_2^2)$ .

## 2.3 条件概率分布与随机变量的独立性

### 2.3.1 条件概率分布的概念

### 2.3.2 离散性随机变量的条件概率分布

#### 1 多项分布

在给定  $X_2 = k_2$  的条件下,  $X_1$  的条件分布为  $B(N - k_2, p_1/(1 - p_2))$ .

### 2.3.3 连续性随机变量的条件概率分布

$$f_1(x_1 | a \leq X_2 \leq b) = \int_a^b f(x_1, t_2) dt_2 / \int_a^b f_2(t_2) dt_2$$

$$\begin{aligned} f(x_1, x_2) &= f_2(x_2)f_1(x_1 | x_2) \\ f(x_1, \dots, x_n) &= g(x_1, \dots, x_k)h(x_{k+1}, \dots, x_n | x_1, \dots, x_k) \end{aligned}$$

$$f_1(x_1) = \int_{-\infty}^{+\infty} f_2(x_2)f_1(x_1 | x_2)dx_2$$

正态变量的条件分布仍为正态. 正态分布[条件分布的中心位置](#)是

$$m(x_1) = b + \rho\sigma_2\sigma_1^{-1}(x_1 - a).$$

## 2.3.4 随机变量的独立性

两个变量的独立  $\Leftrightarrow f_1(x_1) = f_1(x_1 | x_2)$ .

**定义 3.1** 连续型随机变量的相互独立 (独立)

$$X_1, X_2, \dots, X_n \text{ 相互独立 (独立)} \Leftrightarrow f(x_1, \dots, x_n) = f_1(x_1) \cdots f_n(x_n).$$

**定理 3.1**

$$\text{连续变量独立} \Leftrightarrow \text{对应的事件独立}.$$

**定理 3.2**

若连续型随机向量  $(X_1, X_2, \dots, X_n)$  的概率密度函数  $f(x_1, x_2, \dots, x_n) = g_1(x_1)g_2(x_2) \cdots g_n(x_n)$ , 则  $X_1, X_2, \dots, X_n$  相互独立, 且  $f_i(x_i) = Cg_i(x_i)$ .

**定理 3.3**

若  $X_1, X_2, \dots, X_n$  相互独立,

$$Y_1 = g_1(X_1, X_2, \dots, X_m), Y_2 = g_2(X_{m+1}, X_{m+2}, \dots, X_n),$$

则  $Y_1$  和  $Y_2$  独立.

**定义 3.2** 离散性随机变量的相互独立

$X_1, X_2, \dots, X_n$  相互独立 (独立) 等价于

$$\forall a_1, a_2, \dots, a_n: P(X_1 = a_1, \dots, X_n = a_n) = P(X_1 = a_1) \cdots P(X_n = a_n).$$

**示性函数**

$$X = \begin{cases} 1, & \text{当事件 } A \text{ 发生时,} \\ 0, & \text{当事件 } A \text{ 不发生时.} \end{cases}$$

## 2.4 随机变量的函数的概率分布

### 2.4.1 离散性分布

1. 多项分布  $(X_1, X_2, \dots, X_n) \sim M(N; p_1, p_2, \dots, p_n) \Rightarrow X_1 + X_2 \sim B(N; p_1 + p_2)$ .
2. 二项分布  $X_1 \sim B(n_1, p), X_2 \sim B(n_2, p) \Rightarrow X_1 + X_2 \sim B(n_1 + n_2, p)$ .
3. 泊松分布  $X_1 \sim P(\lambda_1), X_2 \sim P(\lambda_2) \Rightarrow X_1 + X_2 \sim P(\lambda_1 + \lambda_2)$ .

### 2.4.2 连续型分布

#### 1 单变量函数

##### 1.1 严格单调

若  $X$  有密度函数  $f(x), Y = g(X)$  且该函数[严格单调](#), 令  $X = h(Y)$ , 则  $Y$  的概率密度函数为

$$l(y) = f(h(y)) |h'(y)|.$$

- $X \sim N(\mu, \sigma^2) \Rightarrow aX + b \sim N(a\mu + b, a^2\sigma^2)$ .

## 1.2 幂函数

若  $X$  有密度函数  $f(x)$ ,  $Y = X^n$ , 其中  $n$  为偶数, 则  $Y$  的概率密度函数为

$$l(y) = \left| \frac{y^{\frac{1}{n}-1}}{n} \right| \left[ f(y^{\frac{1}{n}}) + f(-y^{\frac{1}{n}}) \right]. \quad (n \text{ 是偶数})$$

- 若  $X \sim N(0, 1)$ , 则  $Y = X^2$  的密度函数为  $l(y) = \begin{cases} \left( \sqrt{2\pi y} \right)^{-1} e^{-y/2}, & y > 0, \\ 0, & y \leq 0. \end{cases}$

## 2 多变量函数

以两个为例, 多变量是类似的.

$$\begin{cases} Y_1 = g_1(X_1, X_2) \\ Y_2 = g_2(X_1, X_2) \end{cases} \Rightarrow \begin{cases} X_1 = h_1(Y_1, Y_2) \\ X_2 = h_2(Y_1, Y_2) \end{cases}$$

则雅可比行列式为

$$J(y_1, y_2) = \begin{vmatrix} \frac{\partial h_1}{\partial y_1} & \frac{\partial h_1}{\partial y_2} \\ \frac{\partial h_2}{\partial y_1} & \frac{\partial h_2}{\partial y_2} \end{vmatrix},$$

概率密度函数

$$l(y_1, y_2) = f(h_1(y_1, y_2), h_2(y_1, y_2)) |J(y_1, y_2)|.$$

### 2.4.3 随机变量和的密度函数

设  $(X_1, X_2)$  的联合密度函数为  $f(x_1, x_2)$ , 则  $Y = X_1 + X_2$  的密度函数为

$$l(y) = \int_{-\infty}^{+\infty} f(x, y-x) dx = \int_{-\infty}^{+\infty} f(y-x, x) dx.$$

- 法一: 固定  $y$  后积分得分布函数, 再对  $y$  求导得上式.
- 法二: 补充  $Y_2 = X_1$ , 利用 2.4.2.2

- 
- 二维正态分布的边缘分布的和仍为正态分布

若  $(X_1, X_2) \sim N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$ , 则  $Y = X_1 + X_2 \sim N(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2 + 2\rho\sigma_1\sigma_2)$ .

- 相互独立的正态分布的和仍为正态分布

若  $X_i \sim N(\mu_i, \sigma_i^2)$ , 则  $X_1 + \cdots + X_n \sim N(\mu_1 + \cdots + \mu_n, \sigma_1^2 + \cdots + \sigma_n^2)$ .

- 若  $Y = X_1 + X_2$  服从正态分布,  $X_1, X_2$  独立, 则  $X_1, X_2$  也是正态分布.
- 

自由度为  $n$  的皮尔逊卡方密度与 **卡方分布**  $X \sim \chi_n^2$

$$k_n(x) = \begin{cases} \frac{e^{-x/2} x^{(n-2)/2}}{\Gamma\left(\frac{n}{2}\right) 2^{n/2}}, & x > 0, \\ 0, & x \leq 0. \end{cases}$$

- 若  $X_1, X_2, \dots, X_n$  相互独立, 且有公共分布  $N(0, 1)$  (**独立同分布 iid**), 则  $Y = X_1^2 + X_2^2 + \cdots + X_n^2 \sim \chi_n^2$ .
- 若  $X_1 \sim \chi_m^2$  与  $X_2 \sim \chi_n^2$  独立, 则  $X_1 + X_2 \sim \chi_{m+n}^2$ .
- 若  $X_1, X_2, \dots, X_n$  相互独立, 且都服从指数分布  $E(\lambda)$ , 则  $X = 2\lambda(X_1 + X_2 + \cdots + X_n) \sim \chi_{2n}^2$ .
- $E(\chi_n^2) = n$ .

- $E(\chi_n^2)^{-1} = \frac{1}{n-2}$ .

- $E(\chi_n^2)^k = \frac{2^k \Gamma\left(\frac{n}{2} + k\right)}{\Gamma\left(\frac{n}{2}\right)} \quad (k \in \mathbb{Z})$ .

- $\text{Var}(\chi_n^2) = 2n$ .

注意到方差是均值的两倍, 可以以此检验是否为卡方分布. 🍌

## 2.4.4 随机变量商的密度函数

设  $(X_1, X_2)$  的联合密度函数为  $f(x_1, x_2)$ , 则  $Y = X_2/X_1$  的密度函数为

$$l(y) = \int_0^{+\infty} x_1 f(x_1, x_1 y) dx_1.$$

- 法一: 固定  $y$  后积分得分布函数, 再对  $y$  求导得上式.
- 法二: 补充  $Y_2 = X_1$ , 利用 2.4.2.2

设  $X_1, X_2$  独立,  $X_1 \sim \chi_n^2$ ,  $X_2 \sim N(0, 1)$ ,  $Y = X_2/\sqrt{X_1/n}$ , 则  $Y$  的概率函数为

$$t_n(y) = \frac{\Gamma((n+1)/2)}{\sqrt{n\pi} \Gamma(n/2)} \left(1 + \frac{y^2}{n}\right)^{-\frac{n+1}{2}}.$$

称为自由度为  $n$  的  $t$  分布.

- $E(t_n) = 0$  ( $n > 1$ ).
- $\text{Var}(t_n) = \frac{n}{n-2}$  ( $n > 2$ ).

设  $X_1, X_2$  独立,  $X_1 \sim \chi_m^2$ ,  $X_2 \sim \chi_n^2$ ,  $Y = \frac{X_2}{m} / \frac{X_1}{n}$ , 则  $Y$  的概率密度函数为

$$f_{m,n}(y) = m^{m/2} n^{n/2} \frac{\Gamma\left(\frac{m+n}{2}\right)}{\Gamma\left(\frac{m}{2}\right) \Gamma\left(\frac{n}{2}\right)} y^{m/2-1} (my+n)^{-(m+n)/2} \quad (y > 0)$$

称为自由度为  $(m, n)$  的  $F$  分布.

- $E(f_{m,n}) = \frac{n}{n-2}$  ( $n > 2$ ).
- $\text{Var}(f_{m,n}) = \frac{2n^2(m+n-2)}{m(n-2)^2(n-4)}$ .

★ 若  $X_1, X_2, \dots, X_n$  独立同分布, 且有分布函数  $F(x)$  和密度函数  $f(x)$ , 则

$$\begin{aligned} Y = \max(X_1, X_2, \dots, X_n) &\sim nF^{n-1}(x)f(x), \\ Z = \min(X_1, X_2, \dots, X_n) &\sim n[1-F(x)]^{n-1}f(x). \end{aligned}$$

## 注意事项

- 概率密度函数在某点的取值必为 0. 如果非零, 则不存在这样的概率密度函数. 即混合型随机变量没有概率密度函数.
- 计算随机变量的函数的概率分布时, 注意[单调性](#), [值域](#)和[值域是否重叠](#).

# 第 3 章 随机变量的数字特征

## 3.1 数学期望与中位数

### 3.1.1 数学期望的定义

### 3.1.2 数学期望的性质

**定理 1.1** 随机变量之和的期望

若干个随机变量之和的期望, 等于各变量的期望之和, 即

$$E(X_1 + X_2 + \dots + X_n) = E(X_1) + E(X_2) + \dots + E(X_n).$$

**定理 1.2** 随机变量之积的期望

若干个独立随机变量之积的期望, 等于各变量的期望之积, 即

$$E(X_1 X_2 \cdots X_n) = E(X_1) E(X_2) \cdots E(X_n).$$

#### 定理 1.3 随机变量函数的期望

设随机变量  $X$  为离散型, 有分布  $P(X = a_i) = p_i, i = 1, 2, \cdots, n$ , 或者为连续型, 有概率密度函数  $f(x)$ , 则

$$E(g(X)) = \sum_i g(a_i) p_i \text{ 或 } \int_{-\infty}^{+\infty} g(x) f(x) dx \quad (\text{若求和或极限存在.})$$

### 3.1.3 条件数学期望 (条件均值)

条件期望  $E(Y | x)$  称为  $Y$  对  $X$  的回归函数.

$$E(Y | x) = \int_{-\infty}^{+\infty} y f(y | x) dy.$$

期望等于条件期望的期望

$$\begin{aligned} E(Y) &= \int_{-\infty}^{+\infty} E(Y | x) f_1(x) dx \\ &= E[E(Y | X)] \end{aligned}$$

### 3.1.4 中位数

- 中位数总是存在, 均值则不然.
- 中位数可以不唯一.

## 3.2 方差与矩

### 3.2.1 方差和标准差

1.  $\text{Var}(X) = E(X - EX)^2 = E(X^2) - (EX)^2$ .
2.  $\text{Var}(aX + b) = a^2 \text{Var}(X)$ .
3. 独立随机变量:  $\text{Var}(X_1 + \cdots + X_n) = \text{Var}(X_1) + \cdots + \text{Var}(X_n)$ .
4.  $E[(X - c)^2] = \text{Var}(X) + (EX - c)^2$ .  
 $\text{Var}(X) = \min_c \{E[(X - c)^2]\}$ , 当且仅当  $c = EX$  时取等.

注: 令  $c = 0$  即得 1. 式.

注意 比较  $\text{Var}(nX_1) = n^2 \text{Var}(X_1)$ , 而独立同分布时  $\text{Var}(X_1 + \cdots + X_n) = n \text{Var}(X_1)$ .

### 3.2.2 矩

定义

1.  $X$  关于  $c$  点的  $k$  阶矩:  $E[(X - c)^k]$ .
2.  $k$  阶原点矩:  $\alpha_k = E(X^k)$ .
3.  $k$  阶中心矩:  $\mu_k = E[(X - EX)^k]$ .

特例

1.  $\alpha_1 = E(X)$ .
2.  $\mu_1 = 0$ .
3.  $\mu_2 = \text{Var}(X)$ .

偏度系数  $\beta_1 = \frac{\mu_3}{\mu_2^{3/2}}$ .

峰度系数  $\beta_2 = \frac{\mu_4}{\mu_2^2}$ .

正态分布  $N(\mu, \sigma^2)$  的峰度系数为 3, 故有时定义峰度系数为  $\mu_4 / \mu_2^2 - 3$ .

## 3.3 协方差与相关系数

### 3.3.1 协方差

1.  $\text{Cov}(X, Y) = E[(X - EX)(Y - EY)]$ .
2.  $\text{Cov}(X, Y) = \text{Cov}(Y, X)$ .
3.  $\text{Cov}(X + Y, Z) = \text{Cov}(X, Z) + \text{Cov}(Y, Z)$ .
4.  $\text{Cov}(a_1X + b_1, a_2Y + b_2) = a_1a_2 \text{Cov}(X, Y)$ .
5.  $2\text{Cov}(X, Y) = \text{Var}(X + Y) - \text{Var}(X) - \text{Var}(Y)$ . ★
6.  $\text{Cov}(X, Y) = E(XY) - E(X)E(Y)$ . ★
7. 若  $X, Y$  独立, 则  $\text{Cov}(X, Y) = 0$ .
8.  $[\text{Cov}(X, Y)]^2 \leq \sigma_1^2 \sigma_2^2$ , 且当且仅当  $Y = a + bX$  时取等.

**施瓦茨不等式**  $E(X^2)E(Y^2) \geq [E(XY)]^2$ , 当且仅当具有线性关系即  $aX + bY = 0$  时取等.

- 由  $E[(Y + tX)^2] \geq 0$  的判别式小于零即得.

**协方差矩阵** 设  $n$  维随机变量  $(X_1, X_2, \dots, X_n)$  中  $X_i$  与  $X_j$  的协方差都存在, 且记作  $c_{ij} = \text{Cov}(X_i, X_j)$ ,  $i, j = 1, 2, \dots, n$ , 则协方差矩阵为

$$C = \begin{pmatrix} c_{11} & c_{12} & \cdots & c_{1n} \\ c_{21} & c_{22} & \cdots & c_{2n} \\ \vdots & \vdots & & \vdots \\ c_{n1} & c_{n2} & \cdots & c_{nn} \end{pmatrix}.$$

其中  $c_{ii} = \text{Var}(X_i)$ . [多元正态分布中的应用](#)

### 3.3.2 相关系数

1.  $\text{Corr}(X, Y) \equiv \text{Cov}(X, Y) / (\sigma_1 \sigma_2)$ .
  - 相关系数也可以记作
2.  $\text{Corr}(X, Y) = \text{Corr}(Y, X)$ .
  - 相关系数矩阵是对称阵.
3.  $\text{Corr}(a_1X + b_1, a_2Y + b_2) = \text{Corr}(X, Y)$ .
  - 相关系数不受单位影响.
4. 若  $X, Y$  独立, 则  $\text{Corr}(X, Y) = 0$ .
  - 若  $\text{Corr}(X, Y) = 0$  则称  $X$  与  $Y$  **不相关**.
5.  $|\text{Corr}(X, Y)| \leq 1$ , 且当且仅当  $X$  和  $Y$  有严格线性关系时取等.
  - 相关系数又称为线性相关系数.
6. 最小二乘及其均方误差.

$$\begin{aligned} E[(Y - a - bX)^2] &\equiv E[(Y - m_2) - b(X - m_1) - c]^2 \\ &= \sigma_2^2 + b^2 \sigma_1^2 - 2b \text{Cov}(X, Y) + c^2 \\ &\geq \sigma_2^2 + b^2 \sigma_1^2 - 2b \text{Cov}(X, Y) \end{aligned}$$

$$b = \text{Cov}(X, Y) / \sigma_1^2 = \sigma_1^{-1} \sigma_2 \text{Corr}(X, Y) \equiv \sigma_1^{-1} \sigma_2 \rho$$

$$L(X) = m_2 - \sigma_1^{-1} \sigma_2 \rho m_1 + \sigma_1^{-1} \sigma_2 \rho X$$

$$\begin{aligned} E[(Y - L(X))^2] &= \sigma_2^2 + b^2 \sigma_1^2 - 2b \text{Cov}(X, Y) \quad (\text{由最上式}) \\ &= \sigma_2^2 (1 - \rho^2) \end{aligned}$$

---

### 二维正态分布

若  $(X, Y) \sim N(a, b, \sigma_1^2, \sigma_2^2, \rho)$ , 则

1. 即使允许用任何函数  $M(X)$  逼近  $Y$ , 则所得到的最佳逼近仍是  $L(X)$ , 故只需考虑线性逼近已足够.
2. 对于二维正态分布,  $\text{Corr}(X, Y) = \rho$ , 即  $\text{Corr}(X, Y) = 0$  可推出二者独立.

## 3.4 大数定理和中心极限定理

---

### 3.4.1 大数定理

依概率收敛  $Y_n \xrightarrow{P} a \Leftrightarrow \lim_{n \rightarrow \infty} P\{|Y_n - a| < \varepsilon\} = 1$ .

- $X_n \xrightarrow{P} a \Rightarrow g(X_n) \xrightarrow{P} g(a)$ . (其中  $X_n$  可为向量)

马尔科夫不等式 若  $Y$  为只取非负值的随机变量, 则对  $\forall \varepsilon > 0$ , 有

$$P(Y \geq \varepsilon) \leq E(Y)/\varepsilon.$$

切比雪夫不等式 若  $\text{Var}(Y)$  存在, 则

$$P(|Y - EY| \geq \varepsilon) \leq \text{Var}(Y)/\varepsilon^2.$$

大数定理 设  $X_1, X_2, \dots, X_n$  是独立同分布的随机变量, 记它们的公共均值为  $a$ , 方差存在并记为  $\sigma^2$ , 则对  $\forall \varepsilon > 0$ , 有

$$\lim_{n \rightarrow \infty} P(|\bar{X}_n - a| \geq \varepsilon) = 0.$$

伯努利大数定理 即大数定理的特例 (频率收敛于概率)

$$\lim_{n \rightarrow \infty} P(|p_n - p| \geq \varepsilon) = 0.$$

- 大数定理中无需假定  $X_i$  的方差存在也可以证明 (即 **辛钦大数定理**), 不必同分布, 甚至可以不独立.

### 3.4.2 中心极限定理

应用

林德伯格—莱维定理 设  $X_1, X_2, \dots, X_n$  为独立同分布的随机变量,  $E(X_i) = a$ ,  $\text{Var}(X_i) = \sigma^2$  ( $0 < \sigma^2 < \infty$ ), 则对任何实数  $x$ , 有

$$\lim_{n \rightarrow \infty} P\left(\frac{1}{\sqrt{n}\sigma}(X_1 + X_2 + \dots + X_n - na) \leq x\right) = \Phi(x) = \int_{-\infty}^x \frac{e^{-\frac{t^2}{2}}}{\sqrt{2\pi}} dt.$$

- 因此, 任何独立同分布的大量随机变量之和近似服从正态分布.

$$\frac{\sum_{i=1}^n X_i - n\mu}{\sqrt{n}\sigma} \sim N(0, 1) \Rightarrow \bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right).$$

- 误区: 变量本身的分布并未改变. 可以将大量随机变量分为若干组大量随机变量, 分别计算其和, 并验证其符合正态分布. 这个性质可用于参数估计等, 但不可用于检验随机变量的值是否被篡改.

棣莫弗—拉普拉斯定理 上式的特例, 当  $P(X_i = 1) = p$ ,  $P(X_i = 0) = 1 - p$  ( $0 < p < 1$ ) 时, 对任何实数  $x$ , 有

$$\lim_{n \rightarrow \infty} P\left(\frac{1}{\sqrt{np(1-p)}}(X_1 + X_2 + \dots + X_n - np) \leq x\right) = \Phi(x).$$

- 或者说, 若随机变量  $\eta_n \sim B(n, p)$  ( $n = 1, 2, \dots$ ), 则对任何实数  $x$ , 有

$$\lim_{n \rightarrow \infty} P\left\{\frac{\eta_n - np}{\sqrt{np(1-p)}} \leq x\right\} = \Phi(x).$$

估值公式

$$P(t_1 \leq X_1 + X_2 + \dots + X_n \leq t_2) \approx \Phi(y_2) - \Phi(y_1).$$

其中  $y_i = (t_i - np) / \sqrt{np(1-p)}$ , 或修正为

$$\begin{cases} y_1 = \left(t_1 - \frac{1}{2} - np\right) / \sqrt{np(1-p)}, \\ y_2 = \left(t_2 + \frac{1}{2} - np\right) / \sqrt{np(1-p)}. \end{cases}$$

## 3.5 母函数



### 3.5.1 母函数的定义

**整值随机变量** 即只取非负整值的随机变量.

若整值随机变量的概率分布为  $P\{X = k\} = p_k, k = 0, 1, 2, \dots$ , 则其 **母函数** 为

$$G(s) := \sum_{k=0}^{+\infty} p_k s^k = E(s^X).$$

- $G(1)$  收敛且为 1 (而不是书中说的因为某种方式的计算结果为 1 而收敛), 且  $G(-1)$  绝对收敛, 故  $G(s)$  至少在  $[-1, 1]$  上绝对收敛.

### 3.5.2 常见分布的母函数

- 对于  $X \sim B(n, p)$ , 有

$$G(s) = \sum_{k=0}^n \binom{n}{k} p^k q^{n-k} s^k = (ps + q)^n, \quad s \in (-\infty, +\infty).$$

- 对于  $X \sim P(\lambda)$ , 有

$$G(s) = \sum_{k=0}^{+\infty} \frac{\lambda^k e^{-\lambda}}{k!} \cdot s^k = e^{\lambda(s-1)}, \quad s \in (-\infty, +\infty).$$

- 对于  $X \sim G(p)$ , 有

$$G(s) = \sum_{k=1}^{+\infty} p q^{k-1} s^k = \frac{ps}{1 - qs}, \quad s \in \left(-\frac{1}{q}, \frac{1}{q}\right).$$

### 3.5.2 母函数的性质

- $p_k = \frac{G^{(k)}(0)}{k!}, k = 0, 1, 2, \dots$ .
- $E(X) = \sum_{k=1}^{+\infty} k p_k = G'(1)$ .
- $\text{Var}(X) = G''(1) + G'(1) - [G'(1)]^2$ .

若  $X$  的  $k$  阶矩存在, 则有

- $G^{(0)}(1) = 1$ .
- $G^{(1)}(1) = E(X)$ .
- $G^{(2)}(1) = E(X^2) - E(X)$ .
- $G^{(3)}(1) = E(X^3) - 3E(X^2) + 2E(X)$ .
- $G^{(4)}(1) = E(X^4 - 6X^3 + 11X^2 - 6X)$ .

### 3.5.3 独立和的母函数

设整值随机变量  $X \sim P\{X = k\} = a_k$  和  $Y \sim P\{Y = k\} = b_k$  相互独立, 且母函数分别为  $A(s), B(s)$ , 则  $Z = X + Y$  的母函数为

$$G(s) = A(s)B(s) = \sum_{n=0}^{\infty} \sum_{k=0}^n a_k b_{n-k} s^n.$$

若  $n$  个整值随机变量独立同分布, 则  $G(s) = [G_1(s)]^n$ .

## 3.6 特征函数

### 3.6.1 特征函数的定义

设  $X, Y$  为实随机变量, 则称  $Z = X + iY$  为 **复随机变量**.

设  $X$  是实随机变量, 则  $X$  的 **(一维) 特征函数** 为

$$\begin{aligned}
g(t) &= E(e^{itX}) \quad (-\infty < t < +\infty) \\
&= \begin{cases} \int_{-\infty}^{+\infty} e^{itx} f(x) dx, & \text{连续型随机变量,} \\ \sum p_k e^{itx_k} = G(e^{it}), & \text{离散性随机变量.} \end{cases} \\
&= \begin{cases} \int_{-\infty}^{+\infty} f(x) \cos tx dx + i \int_{-\infty}^{+\infty} f(x) \sin tx dx, & \text{连续型随机变量,} \\ \sum p_k \cos tx_k + i \sum p_k \sin tx_k, & \text{离散性随机变量.} \end{cases}
\end{aligned}$$

- 上述级数与广义积分绝对收敛.

### 3.6.2 常见分布的特征函数

常见分布	特征函数
$X \sim B(n, p)$	$g(t) = \sum_{k=0}^n \binom{n}{k} p^k q^{n-k} e^{itk} = (pe^{it} + q)^n$
$X \sim P(\lambda)$	$g(t) = \sum_{k=0}^{+\infty} \frac{\lambda^k e^{-\lambda}}{k!} e^{itk} = e^{\lambda(e^{it}-1)}$
$X \sim G(p)$	$g(t) = \sum_{k=1}^{+\infty} p q^{k-1} e^{itk} = \frac{pe^{it}}{1 - qe^{it}}$
$X \sim U(a, b)$	$g(t) = \int_a^b \frac{e^{itx}}{b-a} dx = \begin{cases} \frac{e^{ibt} - e^{iat}}{it(b-a)}, & t \neq 0, \\ 1, & t = 0. \end{cases}$
$X \sim E(\lambda)$	$g(t) = \int_0^{+\infty} e^{itx} \lambda e^{-\lambda x} dx = \frac{\lambda}{\lambda - it}$
$X \sim N(\mu, \sigma^2)$	$g(t) = \int_{-\infty}^{+\infty} \frac{e^{itx}}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}} dx = e^{i\mu t} = e^{i\mu t - \frac{\sigma^2}{2} t^2}$

### 3.6.3 特征函数的性质

1.  $g(0) = 1$ .
2.  $|g(t)| \leq 1$ .
3.  $g(-t) = \overline{g(t)}$ .
4.  $g(t)$  在  $(-\infty, +\infty)$  上一致连续.
5.  $\forall n \in \mathbb{N}^+, \forall t_i \in \mathbb{R}, \forall z_i \in \mathbb{C}$  :

$$\sum_{j=1}^n \sum_{k=1}^n g(t_j - t_k) z_j \bar{z}_k \geq 0.$$

6. 如果  $X$  的  $n$  阶原点矩存在, 则它的特征函数 的  $n$  阶导数存在, 且

$$g^{(k)}(0) = i^k E(X^k), \quad k = 1, 2, \dots, n.$$

7. 若  $X$  的特征函数为  $g_X(t)$ , 且  $Y = aX + b$  ( $a, b \in \mathbb{R}$ ), 则

$$g_Y(t) = e^{ibt} g_X(at).$$

8. 如果  $X_1$  和  $X_2$  相互独立, 且特征函数分别为  $g_1(t), g_2(t)$ , 则  $Y = X_1 + X_2$  的特征函数为

$$g_Y(t) = g_1(t) g_2(t).$$

类似的, 由性质 6 可得到  $k$  阶原点矩.

### 例题

分鞋: 例 1.7 和 2.4

## 第 4 章 参数估计

# 4.1 数理统计学的基本概念

**总体**（母体）是概率分布族的一员。

**总体分布** 离散性（概率函数），连续型（概率密度函数）

**单参数分布族**

**非参数总体**

**样本大小 (容量)**

**经验分布函数 (样本分布函数)**  $F_n(x) = \{\text{\textit{X}}_1, \text{\textit{X}}_2, \cdots, \text{\textit{X}}_n \text{ 中不大于 } x \text{ 的个数}\} / n.$

即将  $X$  的样本值  $x_1, x_2, \cdots, x_n$  从小到大重排后, 定义经验分布函数如下.

$$\underbrace{x_{(1)}, \cdots, x_{(1)}}_{n_1}, \underbrace{x_{(2)}, \cdots, x_{(2)}}_{n_2}, \cdots, \underbrace{x_{(m)}, \cdots, x_{(m)}}_{n_m},$$
$$F_n(x) = \begin{cases} 0, & x < x_{(1)}, \\ \frac{1}{n} \sum_{i=1}^k n_i, & x_{(k)} \leq x < x_{(k+1)} \\ 1, & x \geq x_{(m)} \end{cases}$$

- $0 \leq F_n(x) \leq 1.$
- $F_n(x)$  单调不减.
- $F_n(-\infty) = 0, F_n(+\infty) = 1.$
- $F_n(x)$  右连续.

**常用统计图**

- 频率直方图** 以  $\frac{f_i}{\Delta t_i}$  为高. 所有小矩形的面积和为 1.
- 条形图** 一般用于小样本离散性随机变量总体分布.

**格列文科定理** 对于任意实数  $x$ , 经验分布函数  $F_n(x)$  以概率 1 一致收敛于总体分布函数  $F(x)$ , 即

$$P \left\{ \lim_{n \rightarrow \infty} \sup_{-\infty < x < +\infty} |F_n(x) - F(x)| = 0 \right\} = 1.$$

- 经验分布函数不确定, 不唯一, 所以在极限外套一个 P.

**统计量** 只依赖于样本, 而不依赖于其未知参数.

- 样本的统计量为  $g(\text{\textit{X}}_1, \text{\textit{X}}_2, \cdots, \text{\textit{X}}_n).$
- 统计量的观测值为  $g(x_1, x_2, \cdots, x_n).$

**样本均值**  $\bar{X} = a_1 = \frac{1}{n} \sum_{i=1}^n \text{\textit{X}}_i.$

- 其观测值记为  $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i.$

**样本离差平方和**  $SS = \sum_{i=1}^n (\text{\textit{X}}_i - \bar{X})^2.$

- 其观测值记为  $ss = \sum_{i=1}^n (x_i - \bar{x})^2.$

**样本方差**  $S^2 = \frac{1}{n-1} \sum_{i=1}^n (\text{\textit{X}}_i - \bar{X})^2.$

- 其观测值记为  $s^2.$
- 标准差又称均方差, 样本标准差的观测值记为  $s.$

**样本原点矩**  $a_k = \frac{1}{n} \sum_{i=1}^n X_i^k$ .

- 或使用  $A_k$  表示样本原点矩, 用  $a_k$  表示其观测值.

**样本中心矩**  $m_k = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^k$ .

- 或使用  $B_k$  表示样本中心矩, 用  $b_k$  表示其观测值.
- 矩称为理论矩, 样本矩称为经验矩, 即经验分布函数的矩.
- $m_2 = \frac{n-1}{n} S^2$ .

**样本协方差**  $S_{XY} = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})$ .

- 其观测值记为  $s_{XY}$ .

**样本相关系数**  $\rho_{XY} = \frac{S_{XY}}{S_X S_Y}$ .

- 其中  $S_X$  和  $S_Y$  为样本均方差. 其观测值为  $\rho_{XY} = \frac{s_{XY}}{s_X s_Y}$ .

样本的 **众数** 记为  $M_0$ .

**次序统计量**  $X_{(1)} \leq X_{(2)} \leq \cdots \leq X_{(n)}$ .

**样本中位数**  $\hat{m} = \begin{cases} X_{((n+1)/2)}, & n \text{ 为奇数,} \\ (X_{(n/2)} + X_{(n/2+1)})/2, & n \text{ 为偶数.} \end{cases}$

## 4.2 点估计

### 4.2.1 矩估计法

$$\alpha_m = \int_{-\infty}^{+\infty} x^m f(x; \theta_1, \cdots, \theta_2) dx \approx a_m = \sum_{i=1}^n X_i^m / n$$

取  $m = 1, 2, \cdots, k$ , 联立方程组即得  $\theta_i \approx \hat{\theta}_i(X_1, \cdots, X_n)$ .

**变异系数**  $\sigma/\mu$ .

### 4.2.2 极大似然估计法

样本  $(X_1, X_2, \cdots, X_n)$  的总体分布函数为

$$L(x_1, \cdots, x_n; \theta_1, \cdots, \theta_k) = f(x_1; \theta_1, \cdots, \theta_k) f(x_2; \theta_1, \cdots, \theta_k) \cdots f(x_n; \theta_1, \cdots, \theta_k) \\ L(X_1, \cdots, X_n; \theta_1^*, \cdots, \theta_k^*) = \max_{\theta_1, \cdots, \theta_k} L(X_1, \cdots, X_n; \theta_1, \cdots, \theta_k)$$

欲得到极大似然估计, 解如下似然方程组

$$\frac{\partial \ln L}{\partial \theta_i} = 0 \quad (i = 1, 2, \cdots, k)$$

### 4.2.3 贝叶斯估计法

先验分布, 先验概率. 允许使用主观概率.

设总体有概率密度  $f(X, \theta)$ , 抽样本  $X_1, X_2, \cdots, X_n$ , 则  $(\theta, X_1, \cdots, X_n)$  的联合密度为

$$h(\theta) f(X_1, \theta) \cdots f(X_n, \theta)$$

由此算出  $(X_1, X_2, \cdots, X_n)$  的边缘密度为

$$p(X_1, X_2, \cdots, X_n) = \int h(\theta) f(X_1, \theta) \cdots f(X_n, \theta) d\theta$$

从而得出  $\theta$  在给定  $X_1, X_2, \cdots, X_n$  的条件密度为

$$h(\theta | X_1, \cdots, X_n) = h(\theta) f(X_1, \theta) \cdots f(X_n, \theta) / p(X_1, \cdots, X_n)$$

一般去上式的均值作为估计, 即

$$\tilde{\theta} = E(h(\theta) | X_1, X_2, \dots, X_n).$$

$h(\theta)$  一般是概率函数, 即满足  $h(\theta) \geq 0$ ,  $\int h(\theta) d\theta = 1$ .

但对于积分域为无穷区间, 或一些特定的分布, 可以采用其它函数, 比如  $h(\theta) = 1$ , 或直接取为先验密度等. 此时  $h(\theta)$  称为 "广义先验密度".

根据  $n$  次独立试验中事件  $A$  发生的次数  $X$  去估计其发生的概率  $p$ , 按照 "同等无知" 原则 (贝叶斯原则), 由上述方法积分得

$$\tilde{p} = \frac{X+1}{n+2}.$$

- 估计正态分布  $N(\mu, \sigma^2)$  中的  $\mu$  时, 取  $h(\mu) = 1$ ;
- 估计正态分布  $N(\mu, \sigma^2)$  中的  $\sigma$  时, 取  $h(\sigma) = \sigma^{-1}$ ;
- 估计指数分布  $E(\lambda)$  中的  $\lambda$  时, 取  $h(\lambda) = \lambda^{-1}$ .

由先验分布  $N(\mu, \sigma^2)$  估计正态总体  $N(\theta, 1)$  中的  $\theta$  为 (取  $h(\theta)$  为先验密度)

$$\tilde{\theta} = \frac{n}{n + \sigma^{-2}} \bar{X} + \frac{\sigma^{-2}}{n + \sigma^{-2}} \mu.$$

不知道为什么将正态总体分布的方差取为 1, 有什么实际应用吗?

## 4.3 点估计的优良性准则

估计的整体性能

1. 无偏性.
  1. 没有系统性的偏差, 即误差的均值为零.
  2. 各次估计的均值依概率收敛至被估计值.
2. 数量指标 (如均方误差).

### 4.3.1 估计量的无偏性

无偏估计量  $\hat{g}$  须满足

$$E_{\theta_1, \dots, \theta_k}[\hat{g}(X_1, \dots, X_n)] = g(\theta_1, \dots, \theta_k).$$

- $m = \bar{X}$  是  $E(X)$  的无偏估计.
- 如果总体均值未知, 则  $S^2 = \sum_{i=1}^n \frac{(X_i - \bar{X})^2}{n-1}$  是  $\text{Var}(X)$  的无偏估计.
- 如果总体均值已知, 则  $m_2 = \sum_{n=1}^{\infty} \frac{(X_i - \bar{X})^2}{n}$  是  $\text{Var}(X)$  的无偏估计.

由  $\sigma^2 = E(S^2) = \text{Var}(S) + (ES)^2$  知,  $S$  总是  $\sigma$  系统性偏低的估计.

- ★ (看思路) 对于正态分布总体  $N(\mu, \sigma^2)$ , 由  $(n-1)S^2/\sigma^2 \sim \chi_{n-1}^2$  算出

$$S/\sigma \sim g(s) = \begin{cases} \frac{(n-1)^{\frac{n-1}{2}}}{2^{\frac{n-3}{2}} \Gamma\left(\frac{n-1}{2}\right)}, & s > 0 \\ 0 & s \leq 0. \end{cases}$$

计算  $E(S) = \sigma \int_0^{+\infty} sg(s) ds$ , 故  $\sigma$  的一个无偏估计是

$$\tilde{\sigma} = \sqrt{\frac{n-1}{2}} \frac{\Gamma\left(\frac{n-1}{2}\right)}{\Gamma\left(\frac{n}{2}\right)} S.$$

- 无偏估计不一定好, 比如  $X \sim P(\lambda)$ , 则  $g(\lambda) = e^{-2\lambda}$  唯一的无偏估计为

$$\hat{g}(X) = \begin{cases} 1, & X \text{ 为偶数,} \\ -1, & X \text{ 为奇数.} \end{cases}$$

## 4.3.2 最小方差无偏估计

### 1 均方误差

$$\begin{aligned} M_{\hat{\theta}}(\theta) &= E_{\theta} [\hat{\theta}(X_1, \dots, X_n) - \theta]^2 \\ &= \text{Var}_{\theta}(\hat{\theta}) + [E_{\theta}(\hat{\theta}) - \theta]^2 \end{aligned}$$

### 2 最小方差无偏估计 (MVU 估计)

注意是最小方差, 而不是最小均方误差. (Minimum Variance Unbiased)

### 3 克拉美 - 劳不等式

对于单参数情况  $f(x, \theta)$ , 为估计  $g(\theta)$ , 记 **费歇尔信息量** 为

$$\begin{aligned} I(\theta) &= E \left[ \left( \frac{\partial f(x, \theta)}{\partial \theta} \right) / f(x, \theta) \right]^2 \\ &= \int \left[ \left( \frac{\partial f(x, \theta)}{\partial \theta} \right)^2 / f(x, \theta) \right] dx \quad (\text{连续的总体分布}) \\ &= \sum_i \left( \frac{\partial f(a_i, \theta)}{\partial \theta} \right)^2 / f(a_i, \theta) \quad (\text{离散的总体分布}) \end{aligned}$$

则对任一 unbiased 估计  $\hat{g} = \hat{g}(X_1, X_2, \dots, X_n)$ , 有 **克拉美 - 劳不等式**:

$$\text{Var}_{\theta}(\hat{\theta}) \geq (g'(\theta))^2 / (nI(\theta)).$$

- **MVU 的均方误差不一定是最小的**, 如对于正态分布  $N(\mu, \sigma^2)$ , 其中  $\mu$  已知, 则  $m_2$  是 MVU 估计, 但  $E(m_2 - \sigma^2)^2 = \frac{2\sigma^4}{n} > E(\frac{m_2}{n+1} - \sigma^2)^2 = \frac{2\sigma^4}{n+1}$ .
- 若  $\hat{\theta}_1$  和  $\hat{\theta}_2$  都是  $\theta$  的 MVU 估计, 则  $a\hat{\theta}_1 + b\hat{\theta}_2 + c$  是  $(a+b)\theta + c$  的 MVU 估计. ★ ★ (利用第三章定理 3.1, 2°)
- 若  $E(X) = \theta$ ,  $\sum_{i=1}^n c_i = 1$ , 则  $\sum_{i=1}^n c_i X_i$  是  $\theta$  的 unbiased 估计, 并且当且仅当  $c_i = \frac{1}{n}$  时, 其为 MVU 估计.

## 4.3.3 估计量的相合性与渐进正态性

### 1 相合性

如果当样本大小  $n$  无限增加时, 估计量  $T(X_1, X_2, \dots, X_n)$  依概率收敛于被估计值, 则称该估计量是相合估计, 即

$$\forall \varepsilon > 0: \lim_{n \rightarrow \infty} P_{\theta_1, \dots, \theta_k} (|T(X_1, \dots, X_n) - g(\theta_1, \dots, \theta_n)| \geq \varepsilon) = 0.$$

具有相合性的例子:  $m(n)$ ,  $m_2(n)$ , 绝大多数极大似然估计等等.

### 2 渐进正态性

- 大样本性质
  - 相合性
  - 渐进正态性
- 小样本性质
  - 无偏性

## 4.4 区间估计

### 4.4.1 基本概念

**奈曼理论** 的原则: 先保证可靠度, 再提升精度.

称区间估计  $[\hat{\theta}_1, \hat{\theta}_2]$  的 **置信系数** 为  $1 - \alpha$ , 如果

$$\exists \alpha > 0, \forall \theta: P_{\theta} (\hat{\theta}_1(X_1, \dots, X_n) \leq \theta \leq \hat{\theta}_2(X_1, \dots, X_n)) = 1 - \alpha.$$

称区间估计  $[\hat{\theta}_1, \hat{\theta}_2]$  的 **置信水平** 为  $1 - \alpha$ , 如果

$$\exists \alpha > 0, \forall \theta : P_{\theta} \left( \hat{\theta}_1(X_1, \dots, X_n) \leq \theta \leq \hat{\theta}_2(X_1, \dots, X_n) \right) \geq 1 - \alpha.$$

$\alpha$  一般取为 0.1, 0.05, 0.01, 0.001.

区间估计的研究对象:

1. 置信系数或置信水平.
2. 区间长度.
3. 区间右端点与左端点之比.

#### 4.4.2 枢轴变量法

上  $\beta$  分位点:  $F(v_{\beta}) = 1 - \beta$ .

下  $\beta$  分位点:  $F(w_{\beta}) = \beta$ .

上  $\beta$  分位点就是下  $1 - \beta$  分位点.

统计三大分布的上  $\beta$  分位点记为:  $\chi_n^2(\beta)$ ,  $t_n(\beta)$ ,  $f_{n,m}(\beta)$ .

利用上  $\beta$  分位点  $w_{\beta}$  寻找区间估计的 **枢轴变量法**:

1. 找一个与被估计参数  $g(\theta)$  有关的统计量  $T$ .
2. 找 **枢轴变量**  $S(T, g(\theta))$ , 使其分布  $F$  与  $\theta$  无关.
3.  $a \leq S(T, g(\theta)) \leq b \Leftrightarrow A \leq g(\theta) \leq B$ .
4.  $P(w_{1-\alpha/2} \leq S(T, g(\theta)) \leq w_{\alpha/2}) = 1 - \alpha$ .

一样本  $t$  区间估计, 为保证长度  $2St_{n-1}(\alpha/2)/\sqrt{n} \leq L$ , 斯泰因提出了 **两阶段抽样** 的方法, 其中追加抽样的次数为

$$m = \begin{cases} 0, & n \leq [4t_{n-1}^2(\alpha/2)S^2/L^2] + 1, \\ n - 1 - [4t_{n-1}^2(\alpha/2)S^2/L^2], & n > [4t_{n-1}^2(\alpha/2)S^2/L^2] + 1. \end{cases}$$

记两次样本全体的均值为  $\bar{X}$ , 则区间估计  $[\bar{X} - L/2, \bar{X} + L/2]$  有置信系数  $1 - \alpha$ .

#### 4.4.3 大样本法

大样本区间估计: 利用 **中心极限定理** 与枢轴变量法.

例如, 一般的, 设总体有均值  $\theta$ , 方差  $\sigma^2$ , 并且都位置, 从样本  $X_1, X_2, \dots, X_n$  做  $\theta$  的区间估计. 由于样本均方差  $S$  是  $\sigma$  的祥和估计, 利用中心极限定理, 当  $n$  足够大时, 有

$$\sqrt{n}(\bar{X} - \theta)/S \sim N(0, 1).$$

以此为枢轴变量, 于是有区间估计

$$\left[ \bar{X} - Su_{\alpha/2}/\sqrt{n}, \bar{X} + Su_{\alpha/2}/\sqrt{n} \right].$$

对于二项分布, 当  $\alpha = 0.05$ ,  $n \geq 40$  时, 有区间长度  $\theta_2 - \theta_1 \leq 0.3$ .

#### 4.4.4 置信界

置信系数 (水平) 为  $\alpha$  的置信上界  $\bar{\theta}$  和置信下界  $\underline{\theta}$ :

$$\begin{aligned} \forall \theta : P_{\theta}(\bar{\theta}(X_1, X_2, \dots, X_n) \geq \theta) &= 1 - \alpha \\ \forall \theta : P_{\theta}(\underline{\theta}(X_1, X_2, \dots, X_n) \leq \theta) &= 1 - \alpha \end{aligned}$$

#### 4.4.5 贝叶斯法

即寻找  $\hat{\theta}_1, \hat{\theta}_2$ , 使得

$$\int_{\hat{\theta}_1}^{\hat{\theta}_2} h(\theta | X_1, \dots, X_n) d\theta = 1 - \alpha \quad (\text{区间估计})$$

$$\int_{-\infty}^{\hat{\theta}} h(\theta | X_1, \dots, X_n) d\theta = 1 - \alpha \quad (\text{置信上界})$$

$$\int_{\hat{\theta}}^{+\infty} h(\theta | X_1, \dots, X_n) d\theta = 1 - \alpha \quad (\text{置信下界})$$

区间估计中确定  $\theta_1, \theta_2$  的方法 (原则):

1. 使  $\hat{\theta}_2 - \hat{\theta}_1$  最小.
2. 使  $\hat{\theta}_2/\hat{\theta}_1$  最小.
3. 取置信水平为  $\alpha/2$  的置信上下界.

## 第 5 章 假设检验

### 5.1 问题提法和基本概念

#### 5.1.1 例子与问题提法

原假设 (零假设, 解消假设), 对立假设 (备择假设).

检验统计量, 接受域, 否定域 (临界域), 临界值.

简单假设, 复合假设. 赘余参数.

#### 5.1.2 功效函数

设  $H_0$  为原假设,  $\Phi$  是基于样本  $X_1, X_2, \dots, X_n$  而对  $H_0$  做的一个检验, 则其 **功效函数** 是未知参数  $\theta_1, \theta_2, \dots, \theta_n$  的函数:

$$\beta_{\Phi}(\theta_1, \theta_2, \dots, \theta_n) = P_{\theta_1, \theta_2, \dots, \theta_n}(\text{在检验 } \Phi \text{ 之下, } H_0 \text{ 被否定})$$

- 当  $(\theta_1, \theta_2, \dots, \theta_n) \in H_0$  时, 上式越小越好.
- 当  $(\theta_1, \theta_2, \dots, \theta_n) \in H_1$  时, 上式越大越好, 此时称为功效函数.

#### 5.1.3 两类错误, 检验的水平

两类错误

1.  $H_0$  正确, 但被否定.
2.  $H_0$  错误, 但被接受.

$$\alpha_{1\Phi}(\theta_1, \theta_2, \dots, \theta_k) = \begin{cases} \beta_{\Phi}(\theta_1, \theta_2, \dots, \theta_k), & (\theta_1, \theta_2, \dots, \theta_k) \in H_0, \\ 0 & (\theta_1, \theta_2, \dots, \theta_k) \in H_1. \end{cases}$$

$$\alpha_{2\Phi}(\theta_1, \theta_2, \dots, \theta_k) = \begin{cases} 0, & (\theta_1, \theta_2, \dots, \theta_k) \in H_0, \\ 1 - \beta_{\Phi}(\theta_1, \theta_2, \dots, \theta_k), & (\theta_1, \theta_2, \dots, \theta_k) \in H_1. \end{cases}$$

$H_0$  的一个水平为  $\alpha$  的检验  $\Phi$ :

$$\beta_{\Phi}(\theta_1, \theta_2, \dots, \theta_k) \leq \alpha \quad (\text{对任何 } (\theta_1, \theta_2, \dots, \theta_k) \in H_0).$$

并使  $\alpha$  仅可能小. 即固定第一类错误概率的原则.

#### 5.1.4 一致最优检验

假设检验问题  $H_0 : H_1$  的一个水平为  $\alpha$  的一致最优检验  $\Phi$ : 即对任何一个其它水平  $\alpha$  的检验  $g$  有

$$\beta_{\Phi}(\theta_1, \theta_2, \dots, \theta_k) \geq \beta_g(\theta_1, \theta_2, \dots, \theta_k) \quad (\text{对任何 } (\theta_1, \theta_2, \dots, \theta_k) \in H_1).$$

- 在总体分布只依赖于一个参数  $\theta$ , 而原假设  $H_0$  是  $\theta \leq \theta_0$  或  $\theta \geq \theta_0$  时, 一致最优检验存在.

### 5.2 重要参数检验

#### 5.2.1 正态总体均值的检验

1 方差  $\sigma^2$  已知



## 2 方差啊 $\sigma^2$ 未知

### 5.2.2 两个正态总体均值差的检验

### 5.2.3 正态分布方差的检验

### 5.2.4 指数分布参数的检验

### 5.2.5 二项分布参数的检验

### 5.2.6 泊松分布参数的检验

### 5.2.7 大样本检验

### 5.2.8 贝叶斯方法

## 5.3 拟合优度检验

### 5.3.1 理论分布完全已知且只取有限个值的情况

### 5.3.2 理论分布只含有限个值但不完全已知的情况

### 5.3.3 对列联表的应用

### 5.3.4 总体分布为一般分布的情况